

Note méthodologique : preuve de concept

1. Dataset retenu

Le dataset utilisé dans cette preuve de concept est un jeu de données d'images issues d'un contexte e-commerce. Il contient des images de produits réparties en plusieurs catégories afin de réaliser une tâche de classification supervisée.

L'objectif est de développer un modèle capable de prédire automatiquement la catégorie d'un produit à partir de son image.

*Le dataset comporte environ **1 050 images réparties en 7 classes**, avec environ **150 images par catégorie**. Les catégories représentent différents types de produits présents sur une plateforme de commerce en ligne.*

Avant l'entraînement des modèles, plusieurs étapes de préparation ont été réalisées :

- *nettoyage des données et suppression des colonnes inutiles ;*
- *association entre les images et leurs labels ;*
- *redimensionnement des images en résolution **224 x 224 pixels** afin d'être compatibles avec les architectures utilisées ;*
- *séparation du dataset en un ensemble d'entraînement (**80 %**) et un ensemble de test (**20 %**) ;*
- *normalisation des valeurs des pixels.*

*La taille réduite du dataset constitue une contrainte importante. Afin de limiter le risque de surapprentissage, une approche de **transfert learning** a été privilégiée : les modèles utilisent des poids pré-entraînés sur de grandes bases d'images afin de bénéficier de connaissances déjà acquises.*

2. Concepts de l'algorithme récent : Vision Transformer (ViT)

Les réseaux convolutifs (CNN) sont historiquement les architectures dominantes en vision artificielle. Cependant, les modèles récents basés sur les Transformers, initialement développés pour le traitement du langage naturel, ont montré de très bonnes performances dans le domaine de l'image.

Le modèle utilisé dans cette étude est un **Vision Transformer (ViT)**.

Contrairement aux CNN qui exploitent des opérations de convolution pour détecter progressivement des motifs locaux (contours, textures, formes), le Vision Transformer considère une image comme une séquence de petits morceaux appelés **patches**.

Une image de taille 224×224 pixels est découpée en plusieurs patches fixes. Chaque patch est ensuite transformé en un vecteur numérique appelé **embedding**.

Le fonctionnement général du ViT est le suivant :

1. **Découpage de l'image en patches**

L'image est divisée en petits blocs, par exemple des patches de 16×16 pixels.

2. **Transformation en embeddings**

Chaque patch est converti en représentation vectorielle afin d'être traité par le Transformer.

3. **Ajout d'informations positionnelles**

Comme le Transformer ne possède pas naturellement de notion d'espace, une information indiquant la position de chaque patch est ajoutée.

4. **Mécanisme d'attention**

Le cœur du modèle repose sur le mécanisme de **Self-Attention**.

Celui-ci permet au modèle d'évaluer les relations entre tous les patches de l'image. Contrairement aux CNN qui analysent principalement les relations locales, le Transformer peut directement prendre en compte des informations globales.

5. **Classification finale**

- 6.

Les représentations extraites sont envoyées dans une couche de classification permettant de prédire la catégorie de l'image.

L'avantage principal du Vision Transformer est sa capacité à comprendre les relations globales dans une image. Cependant, il nécessite généralement davantage de

données pour être entraîné efficacement, ce qui explique l'utilisation de poids pré-entraînés dans cette expérimentation.

3. Modélisation

Deux architectures ont été comparées :

Modèle 1 : ResNet50

Le premier modèle utilisé est un réseau convolutif **ResNet50**.

Cette architecture repose sur des blocs résiduels permettant d'entraîner des réseaux très profonds tout en limitant les problèmes de disparition du gradient.

La structure utilisée :

- modèle ResNet50 pré-entraîné ;
- suppression de la dernière couche de classification ;
- ajout d'un Global Average Pooling ;
- ajout d'un Dropout de 30 % ;
- ajout d'une couche Dense avec activation Softmax pour les 7 classes.

Les paramètres du modèle pré-entraîné ont été gelés afin d'utiliser uniquement les connaissances acquises précédemment.

Modèle 2 : Vision Transformer

Le second modèle correspond à un Vision Transformer pré-entraîné.

L'image est transformée en séquence de patches puis analysée par les couches Transformer utilisant l'attention.

Une nouvelle tête de classification adaptée aux 7 catégories a été ajoutée.

Entraînement

Les deux modèles ont été entraînés avec :

- une fonction de perte : **Sparse Categorical Crossentropy** ;
- un optimiseur : **Adam** ;

- un learning rate de 0,001 ;
- 10 epochs ;
- une taille de batch de 32 images.

Métrique d'évaluation

La métrique principale retenue est :

Accuracy

Accuracy = $\frac{\text{Nombre de prédictions correctes}}{\text{Nombre total de prédictions}}$

Cette métrique est adaptée car le dataset possède un nombre similaire d'images dans chaque catégorie.

Une matrice de confusion a également été utilisée afin d'identifier les classes les plus difficiles à distinguer.

4. Synthèse des résultats

Les performances obtenues sont les suivantes :

Modèle	Accuracy
ResNet50	82,86 %
Vision Transformer	89,05 %

Les résultats montrent que le Vision Transformer obtient une meilleure précision que le modèle CNN classique.

Cette amélioration peut s'expliquer par la capacité du Transformer à analyser les relations globales entre les différentes zones d'une image.

Le modèle ResNet50 reste cependant performant malgré un dataset limité. Son avantage réside dans sa robustesse et son efficacité avec un volume de données réduit.

La comparaison montre donc que les architectures Transformer représentent une évolution intéressante pour les tâches de vision artificielle, particulièrement lorsque des modèles pré-entraînés sont disponibles.

5. Analyse de la feature importance globale et locale

L'interprétation des modèles de deep learning constitue un enjeu important car les réseaux neuronaux sont souvent considérés comme des modèles difficiles à expliquer.

Pour analyser le comportement du Vision Transformer, une méthode d'explicabilité basée sur l'attention a été étudiée.

Importance globale

L'analyse globale permet d'identifier quelles zones générales des images influencent le plus les décisions du modèle.

Dans le cas du Vision Transformer, les scores d'attention indiquent quelles régions de l'image ont été davantage prises en compte lors de la classification.

Cette analyse permet de vérifier que le modèle se concentre principalement sur les éléments pertinents du produit et non sur des éléments parasites du fond.

Importance locale

L'analyse locale consiste à expliquer une prédiction individuelle.

Pour une image donnée, il est possible d'observer les zones ayant contribué positivement ou négativement à la prédiction finale.

Cette interprétation permet de répondre à une question importante :

Pourquoi le modèle a-t-il choisi cette catégorie ?

L'explicabilité améliore donc la confiance dans le modèle et facilite l'identification d'éventuelles erreurs.

6. Limites et améliorations possibles

Plusieurs limites doivent être prises en compte :

- la taille réduite du dataset limite la capacité de généralisation du modèle ;
- certaines classes peuvent présenter des similarités visuelles ;
- le modèle ViT nécessite généralement davantage de données pour exploiter tout son potentiel ;
- l'interprétation des mécanismes d'attention reste encore un domaine de recherche.

Plusieurs améliorations pourraient être envisagées :

- augmenter la taille du dataset ;
- utiliser davantage d'augmentation d'images (rotation, zoom, changement de luminosité) ;
- effectuer un fine-tuning complet des couches du modèle pré-entraîné ;
- tester des architectures plus récentes comme Swin Transformer ou ConvNeXt ;
- utiliser des méthodes d'explicabilité complémentaires comme Grad-CAM ou Integrated Gradients.