

Preuve de concept

Table des matières

1. Présentation du dataset et préparation des données

2. Veille technologique : Vision Transformer (ViT)

2.1 Présentation du modèle Vision Transformer

2.2 Transformation des images en patches

2.3 Mécanisme d'attention (*Self-Attention*)

2.4 Utilisation de ViT dans la preuve de concept

3. Démarche de modélisation

3.1 Modèle de référence : ResNet50

3.2 Modèle étudié : Vision Transformer + Logistic Regression

4. Résultats et comparaison des modèles

4.1 Comparaison des performances

4.2 Analyse de l'apprentissage

4.3 Analyse des résultats

5. Interprétabilité du modèle ViT

5.1 Importance globale des caractéristiques

5.2 Analyse locale d'une prédiction

6. Limites et perspectives d'amélioration

7. Bibliographie

1. Présentation du dataset et préparation des données

Le dataset utilisé dans cette preuve de concept est le **Flipkart E-commerce Dataset**, un jeu de données public composé d'images de produits issues d'un catalogue e-commerce.

L'objectif est de réaliser une classification automatique d'images afin de prédire la catégorie d'un produit à partir de ses caractéristiques visuelles. Cette expérimentation permet d'évaluer l'apport d'une architecture récente basée sur les Transformers de vision (**Vision Transformer - ViT**) par rapport à une architecture convolutionnelle de référence (**ResNet50**).

Le dataset contient **1050 images réparties en 7 catégories de produits** :

- Baby Care ;
- Beauty and Personal Care ;
- Computers ;
- Home Decor & Festive Needs ;
- Home Furnishing ;
- Kitchen & Dining ;
- Watches.

Afin de se concentrer uniquement sur l'information visuelle, seules deux variables ont été conservées :

- l'image du produit ;
- sa catégorie associée.

La préparation des données comprend plusieurs étapes :

- nettoyage et extraction de la catégorie principale des produits ;
- création des chemins d'accès vers les images ;
- redimensionnement des images au format **224 × 224 pixels**, correspondant aux entrées attendues par les modèles pré-entraînés ;
- encodage des catégories sous forme numérique avec un **Label Encoder**.


Le dataset a ensuite été séparé en deux ensembles :

- **840 images pour l'entraînement (80 %) ;**
- **210 images pour l'évaluation finale (20 %).**

Une séparation stratifiée a été utilisée afin de conserver une distribution similaire des différentes classes entre les ensembles d'entraînement et de test.

Cette préparation permet d'obtenir un jeu de données adapté à l'évaluation comparative des architectures étudiées. Une veille technologique a ensuite été

réalisée afin d'identifier une approche récente en vision par ordinateur susceptible d'améliorer cette tâche de classification.



2. Veille technologique : Vision Transformer (ViT)

2.1 Présentation du modèle Vision Transformer

Dans le cadre de cette preuve de concept, le modèle étudié est le Vision Transformer (ViT) présenté dans l'article scientifique :

"An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale"
(Dosovitskiy et al., 2021).

Cette architecture adapte le mécanisme Transformer, initialement développé pour le traitement du langage naturel, aux problématiques de vision par ordinateur.

Contrairement aux réseaux convolutionnels classiques comme ResNet50, qui extraient principalement des informations locales à l'aide de filtres convolutifs, ViT représente une image sous la forme d'une séquence d'éléments appelés **patches**. Le modèle utilise ensuite un mécanisme de Self-Attention permettant de modéliser les interactions entre les différentes régions de l'image, y compris lorsqu'elles sont éloignées spatialement.

Dans cette expérimentation, le modèle utilisé est :

Google ViT-Base-Patch16-224 pré-entraîné sur ImageNet.

2.2 Transformation des images en patches

La première étape du fonctionnement de **Vision Transformer** consiste à transformer une image en une séquence de petits blocs appelés **patches**.

Contrairement aux réseaux convolutionnels classiques qui appliquent directement des filtres sur les pixels, ViT découpe chaque image en petits blocs appelés patches afin de la représenter sous forme d'une séquence compatible avec l'architecture Transformer.

Le modèle utilisé est :

Google ViT-Base-Patch16-224

La notation Patch16 indique que chaque image est découpée en blocs de taille : 16 × 16 pixels

Le nombre total de patches obtenus est calculé avec la formule suivante :

$$N = \frac{H}{P} \times \frac{W}{P}$$

N : nombre total de patches ;

H : hauteur de l'image ;

W : largeur de l'image ;

P : taille d'un patch.

$$N = \frac{224}{16} \times \frac{224}{16}$$
$$N = 14 \times 14 = 196$$

Chaque image est donc transformée en une séquence de **196 patches** avant d'être traitée par le Transformer.

Ces patches sont ensuite convertis en représentations numériques appelées **embeddings**, qui constituent les entrées du mécanisme de **Self-Attention**. Cette transformation permet au modèle d'exploiter les informations visuelles provenant des différentes régions de l'image.

2.3 Mécanisme d'attention (Self-Attention)

Après la transformation de l'image en une séquence de **patch embeddings**, Vision Transformer utilise un mécanisme appelé **Self-Attention**.

Ce mécanisme permet à chaque patch d'évaluer son importance par rapport aux autres patches présents dans l'image. Par exemple, pour identifier une montre, le modèle peut mettre en relation différentes zones comme le cadran et le bracelet afin d'obtenir une représentation plus complète de l'objet.

Le calcul de l'attention repose sur trois représentations principales :

- **Query (Q)** : représente l'information recherchée par un patch ;
- **Key (K)** : représente les informations utilisées pour comparer les différents patches ;
- **Value (V)** : contient l'information transmise après le calcul de l'attention.

Le mécanisme d'attention est défini par la formule suivante :

$$Attention(Q, K, V) = Softmax \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Avec :

- **Q** : matrice des requêtes (*Query*) ;
- **K** : matrice des clés (*Key*) ;
- **V** : matrice des valeurs (*Value*) ;
- **d_k** : dimension des vecteurs utilisés.

Le produit matriciel (QK^T) permet de calculer un score de similarité entre les différents patches. La fonction **Softmax** transforme ensuite ces scores en poids d'attention, indiquant l'importance relative accordée aux différentes régions de l'image.

Ce mécanisme permet ainsi à Vision Transformer d'exploiter les relations entre les différentes parties d'une image lors de la classification.

2.4 Utilisation de ViT dans la preuve de concept

Dans cette expérimentation, ViT est utilisé comme extracteur de caractéristiques visuelles. Les représentations extraites à partir du CLS Token sont ensuite utilisées par un classifieur Logistic Regression afin de réaliser la classification des 7 catégories du jeu de données.

Le pipeline de modélisation est donc :

Image → Prétraitement ViT → Extraction du CLS Token → Logistic Regression → Catégorie prédite

Cette approche basée sur Vision Transformer sera ensuite comparée à une architecture convolutionnelle de référence afin d'évaluer son apport sur ce problème de classification d'images.

3. Démarche de modélisation

Après la préparation du jeu de données, une démarche comparative entre deux architectures de classification d'images a été mise en place.

L'objectif est d'évaluer l'apport d'un modèle récent basé sur les Transformers (**Vision Transformer - ViT**) par rapport à une architecture convolutionnelle de référence (**ResNet50**).

Les deux approches reposent sur une stratégie de **transfert learning** à partir de modèles pré-entraînés sur **ImageNet**. Cette méthode permet d'exploiter des représentations visuelles déjà apprises et de limiter le nombre de paramètres à entraîner sur un jeu de données de taille réduite.

Les deux architectures testées sont présentées dans les sections suivantes.

3.1 Modèle de référence : ResNet50

Le modèle ResNet50 pré-entraîné sur ImageNet est utilisé comme extracteur de caractéristiques visuelles. Ses différentes couches convolutionnelles permettent d'extraire progressivement des informations comme les contours, les textures et les formes présentes dans les images.

Afin d'adapter le modèle aux 7 catégories du jeu de données Flipkart, une nouvelle tête de classification a été ajoutée :

- **Global Average Pooling** : réduit la dimension des caractéristiques extraites par le réseau ;
- **Dropout (0,3)** : limite le risque de surapprentissage ;

- **Dense avec activation Softmax** : fournit une probabilité pour chacune des 7 classes.

Les poids de la base convolutionnelle ResNet50 ont été conservés afin d'exploiter les caractéristiques apprises sur ImageNet. Seule la nouvelle tête de classification a été entraînée pendant **10 epochs** afin d'adapter le modèle aux catégories du jeu de données Flipkart.

3.2 Modèle étudié : Vision Transformer + Logistic Regression

Contrairement à ResNet50, ViT n'est pas utilisé comme classifieur final mais comme extracteur de caractéristiques visuelles.

Après le prétraitement des images, le modèle extrait une représentation numérique de chaque image à partir du **CLS Token**. Ce vecteur constitue une synthèse des informations visuelles extraites par les différentes couches du Transformer.

Ces représentations sont ensuite utilisées comme variables d'entrée d'un modèle **Logistic Regression**, chargé de prédire la catégorie de chaque image parmi les 7 classes du jeu de données Flipkart

Contrairement à ResNet50, qui utilise une tête de classification composée d'une couche Global Average Pooling suivie d'une couche Dense avec activation Softmax, l'approche ViT utilise une Logistic Regression comme classifieur final.

Ce choix permet d'évaluer directement la qualité des représentations extraites par Vision Transformer. La Logistic Regression est un modèle linéaire simple qui apprend uniquement une séparation entre les classes à partir des embeddings produits par ViT.

Dans l'approche ResNet50, la couche Dense finale apprend une transformation supplémentaire des caractéristiques extraites par le réseau convolutionnel. Elle contient davantage de paramètres et réalise une adaptation spécifique au problème de classification.

La comparaison permet donc d'évaluer non seulement la qualité des architectures d'extraction de caractéristiques, mais également l'impact du choix de la tête de classification.

La Logistic Regression contient beaucoup moins de paramètres qu'une tête Dense de réseau profond, ce qui limite le risque de surapprentissage sur un dataset de petite taille.

3.3 Méthode d'évaluation

Les deux modèles ont été évalués sur le même ensemble de test composé de **210 images**, afin de garantir une comparaison équitable des performances.

Les métriques utilisées sont :

- **Accuracy** : proportion globale d'images correctement classées par le modèle. Cette métrique permet d'évaluer la performance générale de classification.
- **F1-score** : moyenne des F1-scores calculés pour chaque classe. Cette métrique combine la précision et le rappel afin d'obtenir une évaluation équilibrée entre les différentes catégories.

Le choix du **F1-score** permet donc de compléter l'accuracy en prenant en compte les performances du modèle sur chacune des classes du jeu de données, sans favoriser uniquement les catégories les plus représentées.

Les résultats obtenus pour les deux architectures sont ensuite comparés afin d'évaluer l'apport de l'approche **Vision Transformer** par rapport au modèle convolutionnel **ResNet50**.

Dans cette expérimentation, aucun fine-tuning complet du modèle Vision Transformer n'a été réalisé. Le modèle pré-entraîné sur ImageNet est utilisé comme extracteur de caractéristiques afin d'évaluer la qualité des représentations apprises. Cette approche est adaptée à un jeu de données limité comme Flipkart contenant 1050 images.

4. Résultats et comparaison des modèles

Afin d'évaluer l'apport du modèle **Vision Transformer (ViT)**, ses performances sont comparées à celles du modèle de référence **ResNet50**.

Les deux architectures ont été évaluées sur le même ensemble de test composé de **210 images**, garantissant ainsi une comparaison équitable des résultats.

4.1 Comparaison des performances

Les performances des deux modèles sont comparées à partir des métriques définies précédemment : **Accuracy** et **F1-score** .

Le modèle **Vision Transformer + Logistic Regression** obtient de meilleures performances que **ResNet50** sur le jeu de données étudié. Il présente une amélioration à la fois en termes d'accuracy globale et d'équilibre entre les différentes catégories, évalué par le **F1-score**

L'accuracy du modèle ViT est supérieure d'environ **12 points** à celle de ResNet50, ce qui met en évidence l'intérêt d'utiliser une représentation basée sur les **Transformers** pour cette tâche de classification d'images.

Cette amélioration peut s'expliquer par la capacité de Vision Transformer à exploiter des représentations visuelles globales grâce au mécanisme de **Self-Attention**, permettant de modéliser les relations entre différentes régions d'une image.


	Modèle	Accuracy	F1_macro
0	ResNet50	0.776190	0.776025
1	ViT + Logistic Regression	0.904762	0.904196

L'accuracy passe de 77,6 % pour ResNet50 à 90,5 % pour ViT + Logistic Regression, soit une amélioration de 12,9 points.

4.2 Analyse de l'apprentissage

L'évolution de l'apprentissage du modèle **ResNet50** montre une progression régulière des performances au cours des **10 epochs**.

L'accuracy d'entraînement évolue de **41 % à 92%**, tandis que l'accuracy de validation atteint environ **85 %**.



Ces résultats montrent que le modèle apprend efficacement les caractéristiques visuelles des images. Cependant, l'écart observé entre les performances d'entraînement et de validation suggère une possible tendance au **surapprentissage**.


Cette différence peut notamment s'expliquer par la taille limitée du jeu de données, qui contient seulement **1050 images**. L'utilisation de techniques supplémentaires, comme

la **data augmentation** ou un **fine-tuning contrôlé**, pourrait permettre d'améliorer la capacité de généralisation du modèle.

4.3 Analyse des résultats

Les résultats montrent que Vision Transformer + Logistic Regression obtient de meilleures performances que ResNet50 sur le jeu de données étudié. Cette amélioration peut s'expliquer par la capacité de ViT à exploiter des représentations visuelles globales grâce au mécanisme de Self-Attention. L'utilisation du transfert learning permet également de bénéficier de représentations apprises sur ImageNet malgré la taille limitée du jeu de données.

Néanmoins, ces résultats doivent être interprétés avec prudence en raison de la taille limitée du jeu de données. Des expérimentations complémentaires sur un volume plus important seraient nécessaires pour confirmer la généralisation du modèle.



L'écart de performance observé entre les deux modèles peut également être lié à la nature des représentations utilisées. Les embeddings extraits par ViT semblent contenir une information suffisamment discriminante pour permettre à un modèle linéaire simple comme Logistic Regression d'obtenir de bonnes performances. Cela indique que le Transformer a appris des représentations visuelles générales efficaces.

5. Interprétabilité du modèle Vision Transformer

L'objectif de cette analyse est de mieux comprendre les éléments influençant les décisions du modèle **Vision Transformer (ViT)**.

Les modèles de Deep Learning produisent généralement des représentations internes complexes, difficiles à interpréter directement. Dans cette expérimentation, ViT transforme chaque image en une représentation numérique extraite à partir du **CLS Token**. Ces caractéristiques sont ensuite utilisées par le classifieur **Logistic Regression** pour réaliser la classification finale.

L'analyse des coefficients du classifieur permet d'étudier l'influence des caractéristiques extraites par ViT et de mieux comprendre le comportement du modèle.

5.1 Importance globale des caractéristiques

Une analyse globale a été réalisée afin d'identifier les caractéristiques ayant le plus d'influence sur les prédictions du modèle.

Les coefficients appris par la **Logistic Regression** sont utilisés comme indicateur d'importance. La valeur absolue de ces coefficients permet de mesurer la contribution de chaque dimension du vecteur extrait par ViT, sans tenir compte du sens de l'influence (positive ou négative).

Les caractéristiques présentant les valeurs d'importance les plus élevées correspondent donc aux dimensions de l'embedding ViT ayant le plus fort pouvoir discriminant pour séparer les différentes catégories du jeu de données.

Cette analyse permet d'identifier les représentations internes les plus utiles pour la classification. Cependant, ces caractéristiques restent abstraites et ne correspondent pas directement à des éléments visuels identifiables comme une couleur, une forme ou une partie précise d'un objet.

5.2 Analyse locale d'une prédiction

Afin d'étudier le comportement du modèle sur des exemples individuels, une analyse locale a été réalisée sur des erreurs de classification.

L'objectif est d'identifier les images mal classées malgré une forte probabilité du modèle.

La sélection des exemples repose sur trois critères :

- la classe réelle correspond à **Baby Care** ;
- la prédiction du modèle est incorrecte ;
- la probabilité minimale de prédiction est supérieure à **90 %**.

Ces exemples permettent d'analyser les situations dans lesquelles le modèle produit une décision erronée avec une forte certitude.

L'étude de ces cas particuliers met en évidence certaines ambiguïtés visuelles entre catégories. Par exemple, certains produits peuvent partager des caractéristiques visuelles proches, ce qui peut conduire le modèle à confondre deux catégories différentes.

Une analyse a été réalisée sur la catégorie Baby Care, qui présente un rappel de 80 %, inférieur aux autres catégories. Certaines images sont mal classées avec une forte confiance, ce qui montre une ambiguïté visuelle entre certaines catégories.

Par exemple, certains produits Baby Care peuvent être confondus avec Beauty and Personal Care en raison de similarités au niveau du packaging, des couleurs ou de la forme des produits.

Predit : Home Furnishing
Confiance : 99.19%



Baby Care




5.3 Saliency maps

Afin de compléter l'analyse locale basée sur les erreurs de classification, des cartes de saillance (saliency maps) ont été utilisées pour visualiser les régions de l'image ayant contribué à la décision du modèle.

Contrairement à l'analyse des coefficients de la Logistic Regression, qui porte sur les représentations internes extraites par ViT, les cartes de saillance permettent d'étudier l'influence directement au niveau des pixels.

Le principe consiste à calculer le gradient de la sortie du modèle par rapport aux pixels de l'image. Les zones présentant un gradient élevé correspondent aux régions ayant le plus influencé la prédiction.



Cette approche permet d'obtenir une interpr  tation locale plus intuitive en reliant la d  cision du mod  le aux   l  ments visuels pr  sents dans l'image.

6. Limites et am  liorations possibles

Cette preuve de concept pr  sente plusieurs limites qui doivent   tre prises en compte dans l'interpr  tation des r  sultats.

La premi  re concerne la taille du jeu de donn  es. Avec seulement 1050 images r  parties en 7 cat  gories, le volume de donn  es reste limit   pour   valuer pleinement la capacit   de g  n  ralisation du mod  le. Un jeu de donn  es plus important permettrait de confirmer la robustesse des performances obtenues.

La seconde limite concerne l'utilisation de Vision Transformer comme extracteur de caractéristiques. Le modèle utilisé est pré-entraîné sur ImageNet, mais n'a pas fait l'objet d'un fine-tuning complet sur les images de produits. Une adaptation plus poussée pourrait permettre d'améliorer les performances sur cette tâche spécifique.

Les principales améliorations envisageables sont donc :

- augmenter la taille du jeu de données ;
- utiliser davantage de techniques de data augmentation afin d'améliorer la généralisation ;
- réaliser un fine-tuning de Vision Transformer sur le jeu de données cible ;
- utiliser des méthodes de visualisation permettant de mieux relier les prédictions aux régions importantes des images.
- Malgré l'utilisation des coefficients de la Logistic Regression et des cartes de saillance, l'interprétation de Vision Transformer reste limitée. Les dimensions de l'embedding ViT ne correspondent pas directement à des concepts visuels humains. Des méthodes spécifiques aux Transformers comme Attention Rollout pourraient compléter cette analyse.

7. Bibliographie

- Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). *Attention Is All You Need*. Advances in Neural Information Processing Systems (NeurIPS).
- An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale, Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al. (2021). *International Conference on Learning Representations (ICLR)*.